Universidade Federal do Ceará
Departamento de Engenharia Elétrica

Comparação entre Vision Transformers e U-Net com MobileNetV2 na Segmentação de Exsudatos Lipídicos em Imagens de Retinografia

Por: Pedro Florencio de Almeida Neto
Matrícula: 389276
Curso: Engenharia Elétrica
Fortaleza, Ceará, 26 de janeiro de 2026

Sumário

Icons created by srip - Flaticon (https://www.flaticon.com/free-icons)

Introdução

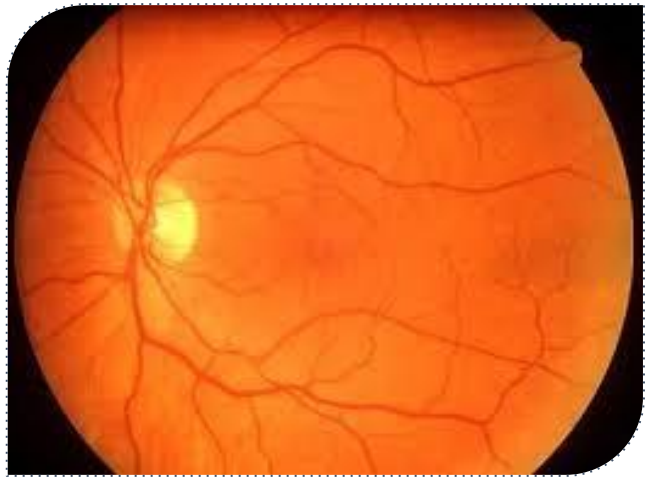

Figura 01 – Fundo de Olho Saudável[2]

- Segundo o Ministério da Saúde e a Organização Mundial da Saúde (OMS), o número de pessoas no mundo que têm a visão prejudicada é cerca de 285 milhões, sendo entre 60% a 80% dos casos evitáveis. Somente no Brasil, 35 milhões de pessoas sofrem com algum tipo de dificuldade visual[1].

- O diagnóstico oftalmológico depende muitas vezes da interpretação de imagens médicas, como retinografias ou tomografia de coerência óptica.

[1] IBGE, 2010.
[2] Adaptado de Oclusões Retinianas, disponível em: <https://oftalmologistapedropaulo.com.br/2020/11/26/oclusoes-retinianas/>. Acesso em: 12 jan. 2026.

Introdução

Figura 02 – Fundo de Olho com Retinopatia Diabética[4]

- Cerca de 20 milhões de pessoas sofrem com Diabetes no Brasil[3];
- A Retinopatia Diabética afeta de 24 a 39% das pessoas diabéticas no Brasil, sendo uma das principais causas de perda de visão;
- 90% dos diabéticos do tipo 1 e 60% do tipo 2 terão algum grau de retinopatia diabética;
- Estudos sugerem que o risco de cegueira pode ser reduzido para menos de 5% se a doença for diagnosticada e tratada precocemente.

[3] Sociedade Brasileira de Diabetes.
[4] Extraído de PORWAL *et al.* (2018).

Introdução

- Uma das principais características da Retinopatia Diabética é a presença dos exsudatos lipídicos (ou duros);

- Este trabalho visa comparar dois modelos de segmentação semântica para o realce de exsudatos duros em imagens de fundo de olho.

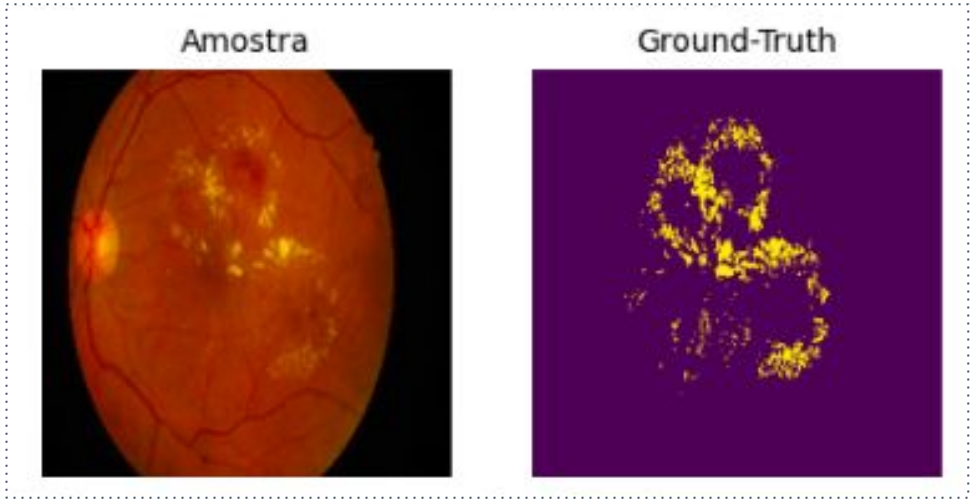

Figura 03 – Segmentação dos exsudatos duros[5]

[5] Elaborado pelo autor.

Justificativa

1. Alta prevalência de Diabetes no Brasil

Gráfico 01 – Percentual da população das capitais com diagnóstico de Diabetes

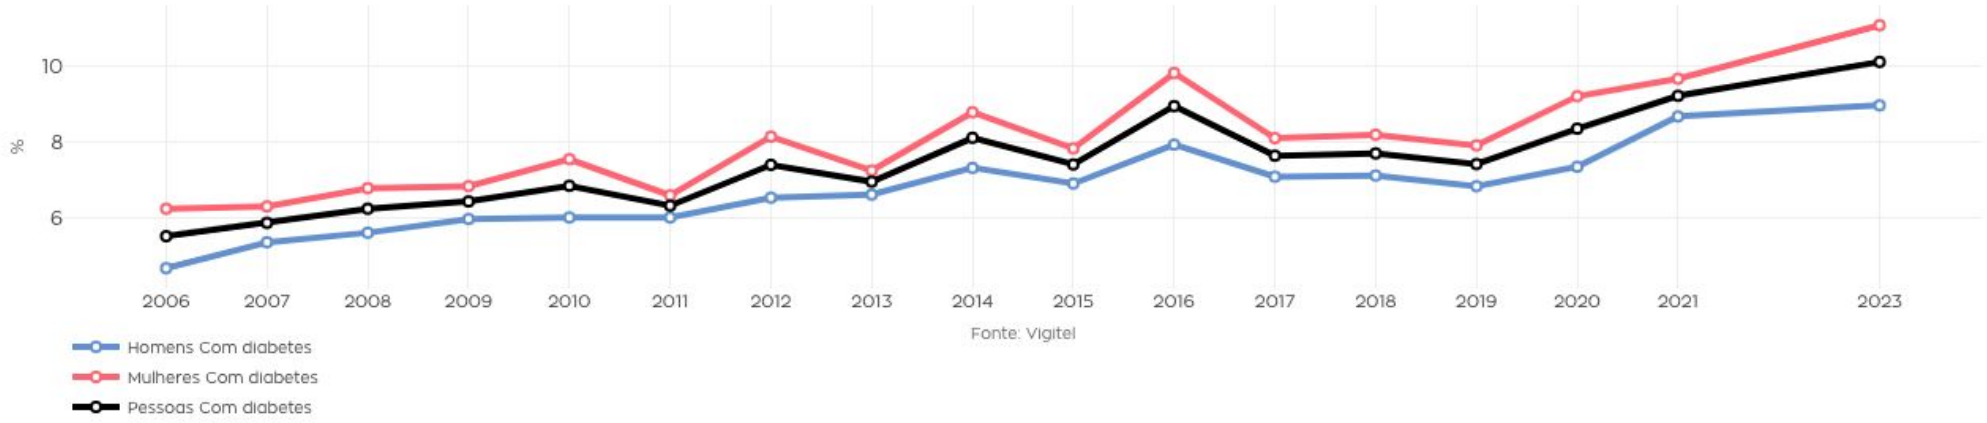

Fonte: Observatório da Saúde Pública. Disponível em: <https://observatoriosaudepublica.com.br/>. Acesso em: 24 jan. 2026.

Justificativa

2. Avanço das tecnologias dos retinógrafos portáteis

Oportunidade de implementação de algoritmos de detecção de doenças oculares em retinógrafos portáteis, para acelerar o diagnóstico por especialistas e democratizar o acesso a exames de fundo de olho, possibilitando o diagnóstico por telemedicina, a quilômetros de um médico oftalmologista.

Figura 05 – Notícia da Universidade de São Paulo sobre retinógrafo portátil[6]

Figura 04 – Retinógrafo Phelcom Eyer 2[5]

Justificativa

[7] Disponível em: <www.upf.br/noticia/projeto-de-retinografo-portatil-de-baixo-custo-conquista-registro-de-desenho-industrial>. Acesso em: 25 jan. 2026

2. Avanço das tecnologias dos retinógrafos portáteis

Oportunidade de implementação de algoritmos de detecção de doenças oculares em retinógrafos portáteis, para acelerar o diagnóstico por especialistas e democratizar o acesso a exames de fundo de olho, possibilitando o diagnóstico por telemedicina, a quilômetros de um médico oftalmologista.

PESQUISA E INOVAÇÃO

Projeto de retinógrafo portátil de baixo custo conquista registro de desenho industrial

15/12/2022 09:06

Por: Assessoria de Imprensa Fotos: Caroline Lima

Iniciativa de startup incubada no UPF Parque tem valor acessível e filtros inovadores que ampliam as possibilidades de diagnóstico de doenças oculares, mesmo em áreas remotas

Figura 06 – Notícia de registro de patente de retinógrafo portátil[7]

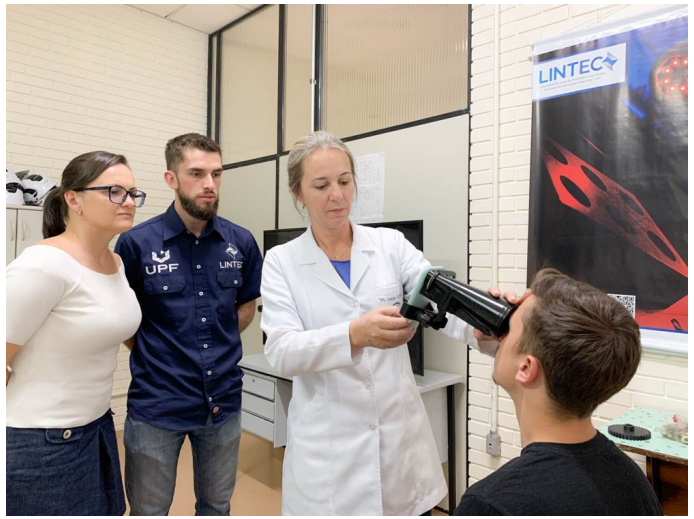

Figura 07 – Pesquisadores do PPGEH - UPF realizando retinografia com *smartphone*[7]

[8] Adaptado de PRAYOGO *et al.* (2023)

Justificativa

2. Avanço das tecnologias dos retinógrafos portáteis

	Peek Retina[21]	D-EYE[20,21]	DIY Solution by Sankara[21]	Paxos Scope[19,21]	MII Ret Cam[13]	CellScope Retina[14]
Device characteristics						
Compatible with	Samsung Galaxy S4	iPhone 5 and Samsung Galaxy S4	Samsung Galaxy S4	iPhone 5s and iPod Touch	iPhone 5s	iPhone 5s
Principle of work	Direct ophthalmoscopy method	Direct ophthalmoscopy method	Direct ophthalmoscopy method	Indirect ophthalmoscopy method	Indirect ophthalmoscopy method	Indirect ophthalmoscopy method
Illumination source	NR	NR	Single LED with external battery attached to the smartphone	Simple external LED	Built-in smartphone's flash	Single white LED
Lens type	NR	NR	NR	Volk Digital ClearField lens[19] and pan retinal 2.2 lens from Volk Optical[21]	20 D lens	54 D ophthalmic lens

Figura 08 – Tabela de retinógrafos portáteis baseados em *smartphones* na literatura[8]

Objetivos

Objetivo Geral: Analisar e comparar o desempenho de abordagens algorítmicas baseadas em CNNs e ViT, do campo da Visão Computacional, na tarefa de segmentação semântica de exsudatos lipídicos em imagens de fundo de olho, classificando os pixels relacionados ao fundo e aos depósitos de lipídio.

Objetivos Específicos:

1. Segmentar exsudatos lipídicos em imagens de fundo de olho com abordagem de U-Net com MobileNetV2 como *encoder*;

2. Segmentar exsudatos lipídicos em imagens de fundo de olho com uso de *ViT*, a partir da arquitetura MobileViT;

3. Comparar o coeficiente de Dice, IoU e tempo de inferência nas duas abordagens modeladas.

Fundamentação Teórica

1. Retinopatia Diabética

- Doença ocular oriunda de uma complicação microvascular na retina, que atinge pessoas com diabetes;
- Pode causar perda de visão se não tratada de forma precoce.

Grau de Retinopatia Diabética	Achados oftalmológicos observáveis
RD Ausente	• Sem anomalias
RD Não Proliferativa Leve	• Microaneurismas
RD Não Proliferativa Moderada	• Microaneurismas • Hemorragias
RD Não Proliferativa Grave	• Hemorragias intrarretinianas • Anomalias microvasculares intrarretinianas • Exsudatos
RD Proliferativa	RD não proliferativa grave e 1 ou mais dos seguintes: • Neovascularização • Hemorragia vítrea/pré-retiniana

Figura 09 – Graus de Retinopatia Diabética[9]

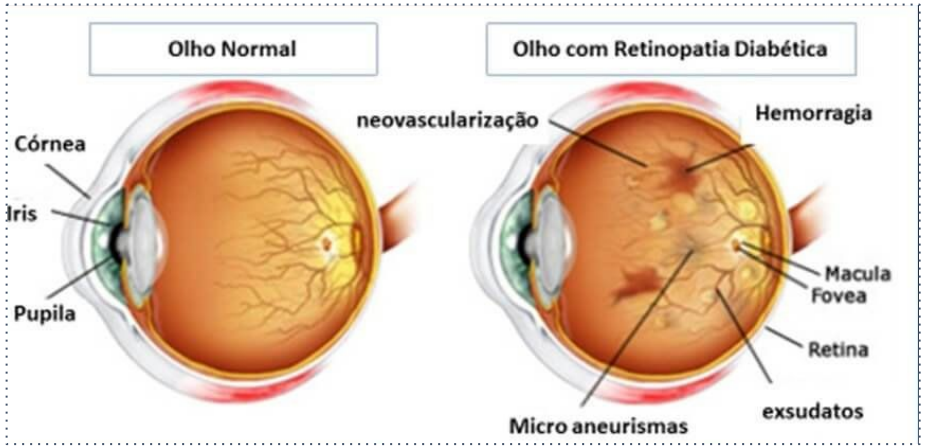

Figura 10 – Diferença entre olho normal e olho com Retinopatia Diabética[10]

[9] Adaptado de CISNEROS-GUZMÁN *et al.* (2019)

[10] RODRIGUEZ, Ever. **Retinopatia Diabética é uma das principais complicações da Diabetes.** Eyeco, 16 fev. 2021. Disponível em: https://www.eyeco.com.br/post/retinopatia-diabética. Acesso em: 25 jan. 2026.

Fundamentação Teórica

2. Fundoscopia Dilatada

- Conhecida como oftalmoscopia ou “fundo de olho”, é um exame feito para observar estruturas da parte interna dos olhos. São elas: o nervo óptico, a retina, e as veias e artérias responsáveis pelo fluxo sanguíneo da área;

- A fundoscopia é um exame não invasivo, portanto, indolor. Normalmente, é necessária a aplicação de um colírio para a dilatação da pupila do paciente.

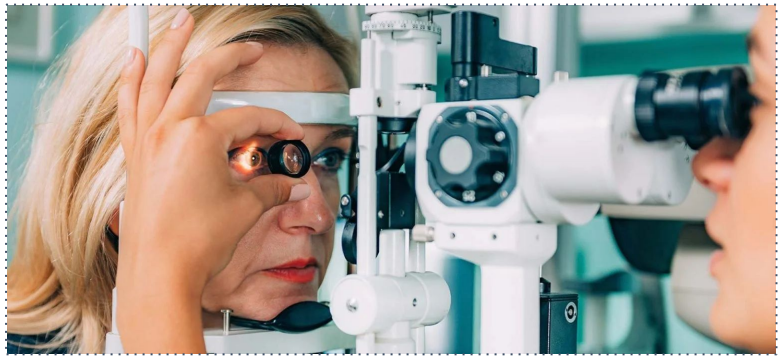

Figura 11 – Lâmpada de fenda para exame de fundo de olho[10]

[10] COE RIO. Fundoscopia (exame de fundo de olho) com segurança, em Botafogo. Rio de Janeiro, jan. 2025. Disponível em: https://coerio.com.br/2025/01/fundoscopia-exame-de-fundo-de-olho-com-seguranca-em-botafogo/. Acesso em: 25 jan. 2026.

Fundamentação Teórica

3. Retinógrafos Portáteis

- Democratização do acesso a exames de fundo de olho e possibilitar a ampliação da telemedicina para o campo da oftalmologia.

- PRAYOGO et al. (2023) avaliam seis tipos de retinógrafos concebidos a partir dos *smartphones* iPhone 5, iPhone 5s e Samsung Galaxy S4, que visam a elaboração de um dispositivo de baixo custo para fotografia da retina.

- No Brasil, destaca-se o projeto desenvolvido pela Fundação Universidade de Passo Fundo (UPF), por meio da startup Mirabile Visu Startup Ltda retinógrafo Phelcom Eyer 2.

Fundamentação Teórica

3. Retinógrafos Portáteis

Figura 12 – Retinógrafo Canon CX1 (não portátil)[11]

Figura 13 – Retinógrafo portátil Phelcom Eyer[12]

[11] Para mais informações acesse: <https://www.apramed.com.br/v4/produtos_detalhes.php?id=254>. Acesso em: 25 jan. 2026

[12] Para mais informações acesse: <https://www.apramed.com.br/v4/produtos_detalhes.php?id=312>. Acesso em: 25 Jan. 2026

[13] MATIAS *et al.* (2021, p.14)

Fundamentação Teórica

4. Paradigmas da Visão Computacional

Paradigm	Domain	Step/Action in the Processing Pipeline			
		I.Filtering and Pre-Processing	II.Conditioning and Simplifying	III.Labelling and Description	IV.Interpretation and Description
		Enhance the image	Simplify an image	Describe an image	Reason about an image
Classic Computer Vision	1.Value	Windowing and scale transform	Thresholding, arithmetic and logic operations with pixels	Histogram analysis	
	2.Space	Despeckling, mathematical morphology operations, convolutional and diffusion filters	Convolutional-based edge detection (Marr, Canny, Sobel, etc), saliency detection (Shaa'shua, etc), region-growing segmentation (watershed, Mumford-Shah, CSC, etc), skeletonization, split & merge	Spatial classifiers, classic ANNs (backpropagation, Boltzmann, Kohonen), statistic classifiers, classic machine learning (SVM, IBL, random forests, etc), rule-based classifiers, feature detection (SIFT, SURF, etc)	Spatial data structures (octrees, quadtrees), face-based models (DLFL, etc), boundary models, graph-based and spatial grammars, semantic networks
	3.Frequency	FFT- and wavelet-based filters (low-, band- and high-pass, etc)	FFT- and wavelet-based operations for frequency elimination, grouping and separation	FFT- and wavelet-based classification methods, Gabor filters	
Deep Learning	Convolutional Neural Networks	AlexNet, VGG, ResNet, Inception, YOLO, SSD, Mask-RCNN, etc			
Transform/Mapping		I → I	I → I	I → M	M → M

Figura 14 – Paradigmas da Visão Computacional[13]

Fundamentação Teórica

5. Segmentação de Imagens

- Separação entre objeto e ambiente

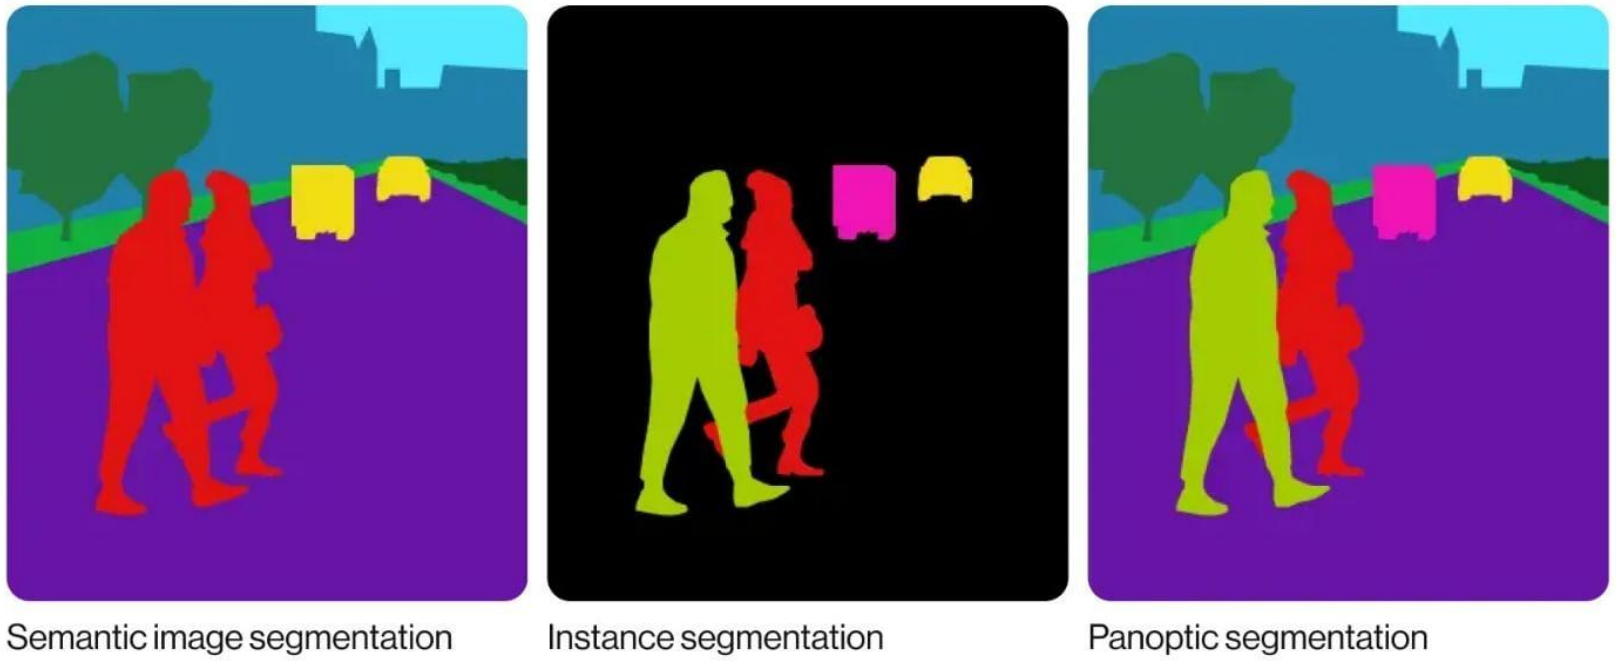

Figura 15 – Tipos de segmentação de imagens[14]

[14] Instance Segmentation Explained: From Techniques to Practical Applications, disponível em: <https://tech-stack.com/blog/instance-segmentation-computer-vision/>. Acesso em 13 jan. 2026

Fundamentação Teórica

5. Segmentação de Imagens

- Avaliação de desempenho de uma segmentação semântica

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN}$$

Onde:

- TP (*True Positive*): Verdadeiros Positivos;
- TN (*True Negative*): Verdadeiros Negativos;
- FP (*False Positive*): Falsos Positivos;
- FN (*False Negative*): Falsos Negativos.

$$\text{Dice} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

[15] LECUN *et al.* (1998, p. 2283)

Fundamentação Teórica

6. Redes Neurais Convolucionais

- Camadas de convolução
- Função de ativação
- Camadas de *pooling*
- Camada *fully connected*
- *Loss function*

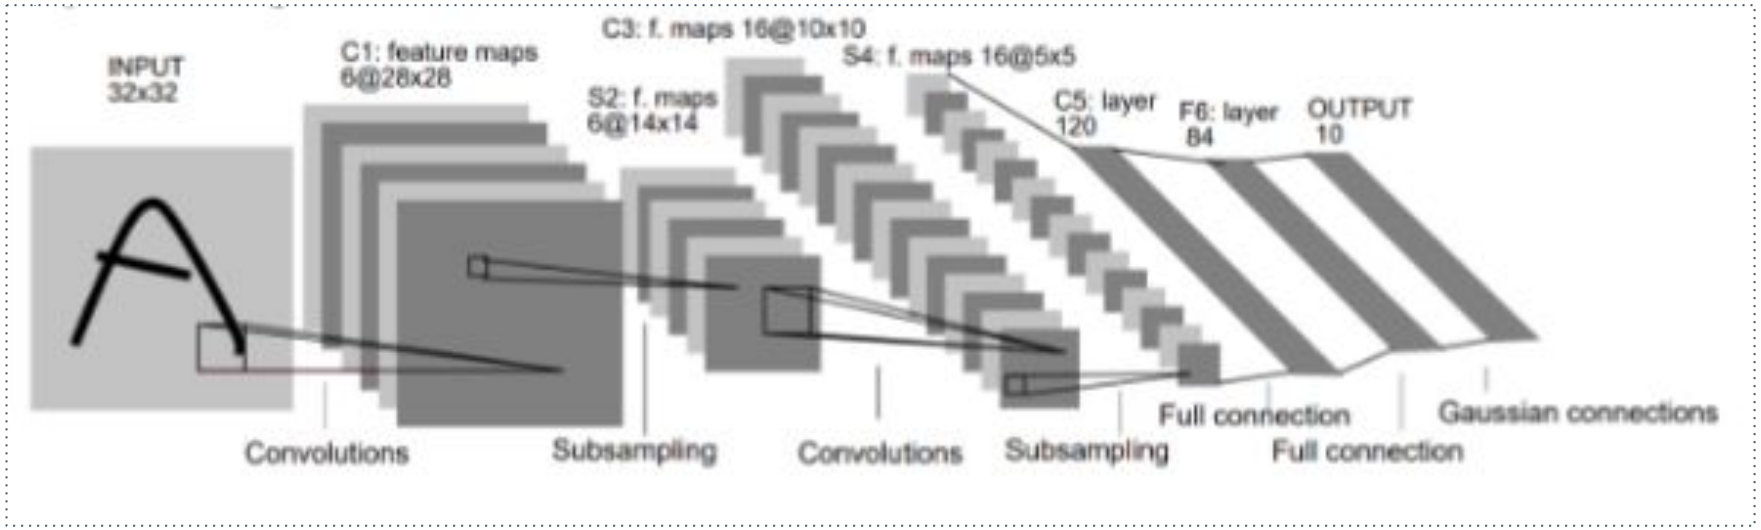

Figura 16 – Arquitetura LeNet-5[15]

[16] Azad et al. (2023, p. 2)

Fundamentação Teórica

6. Redes Neurais Convolucionais – Funções de Perda

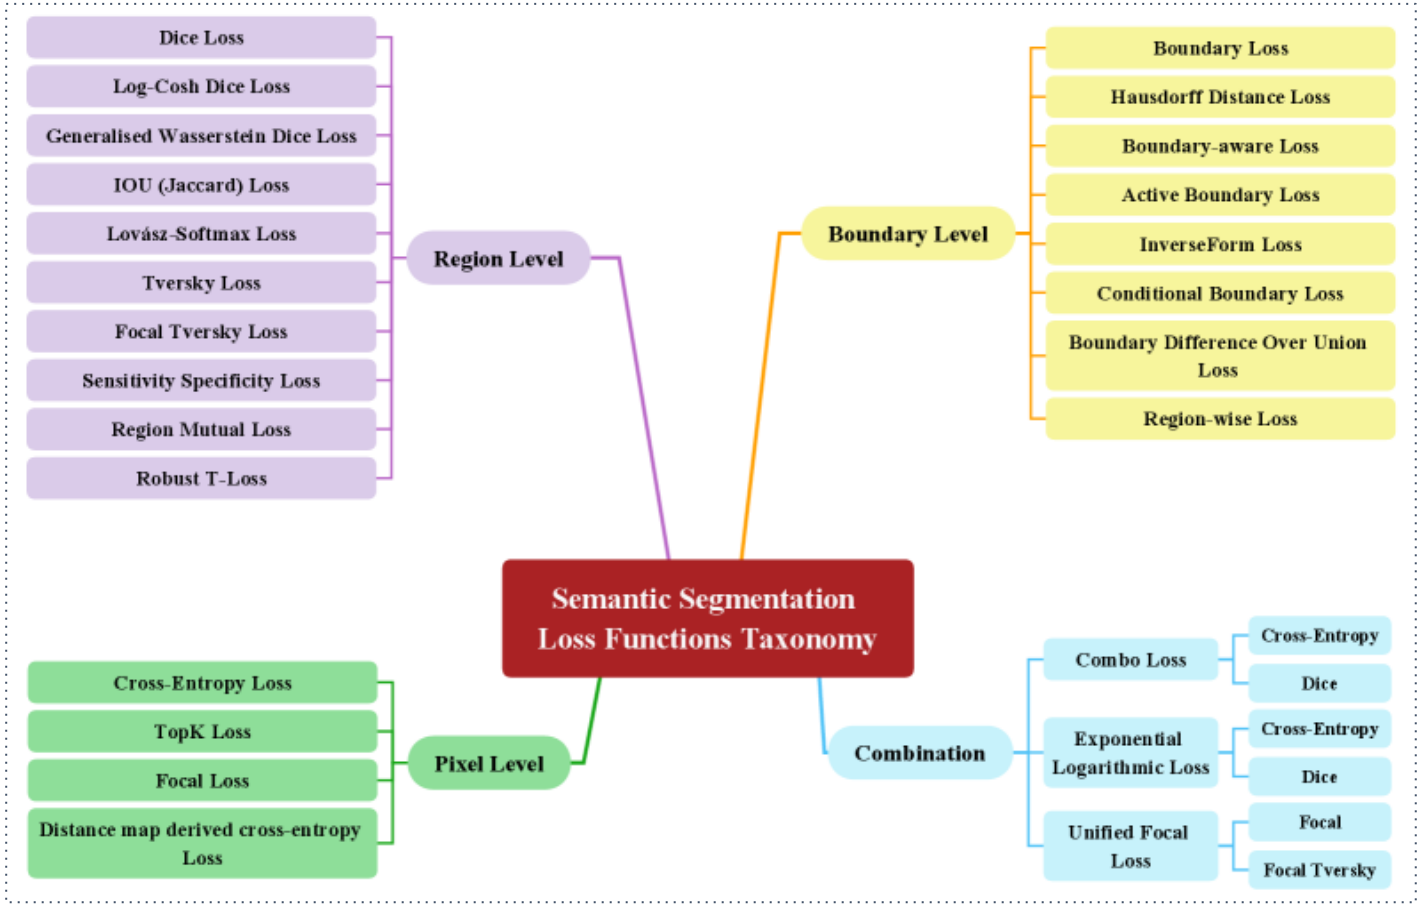

Figura 17 – Funções de perda para segmentação semântica[16]

[16] Azad et al. (2023, p. 2)

Fundamentação Teórica

6. Redes Neurais Convolucionais – Funções de Perda

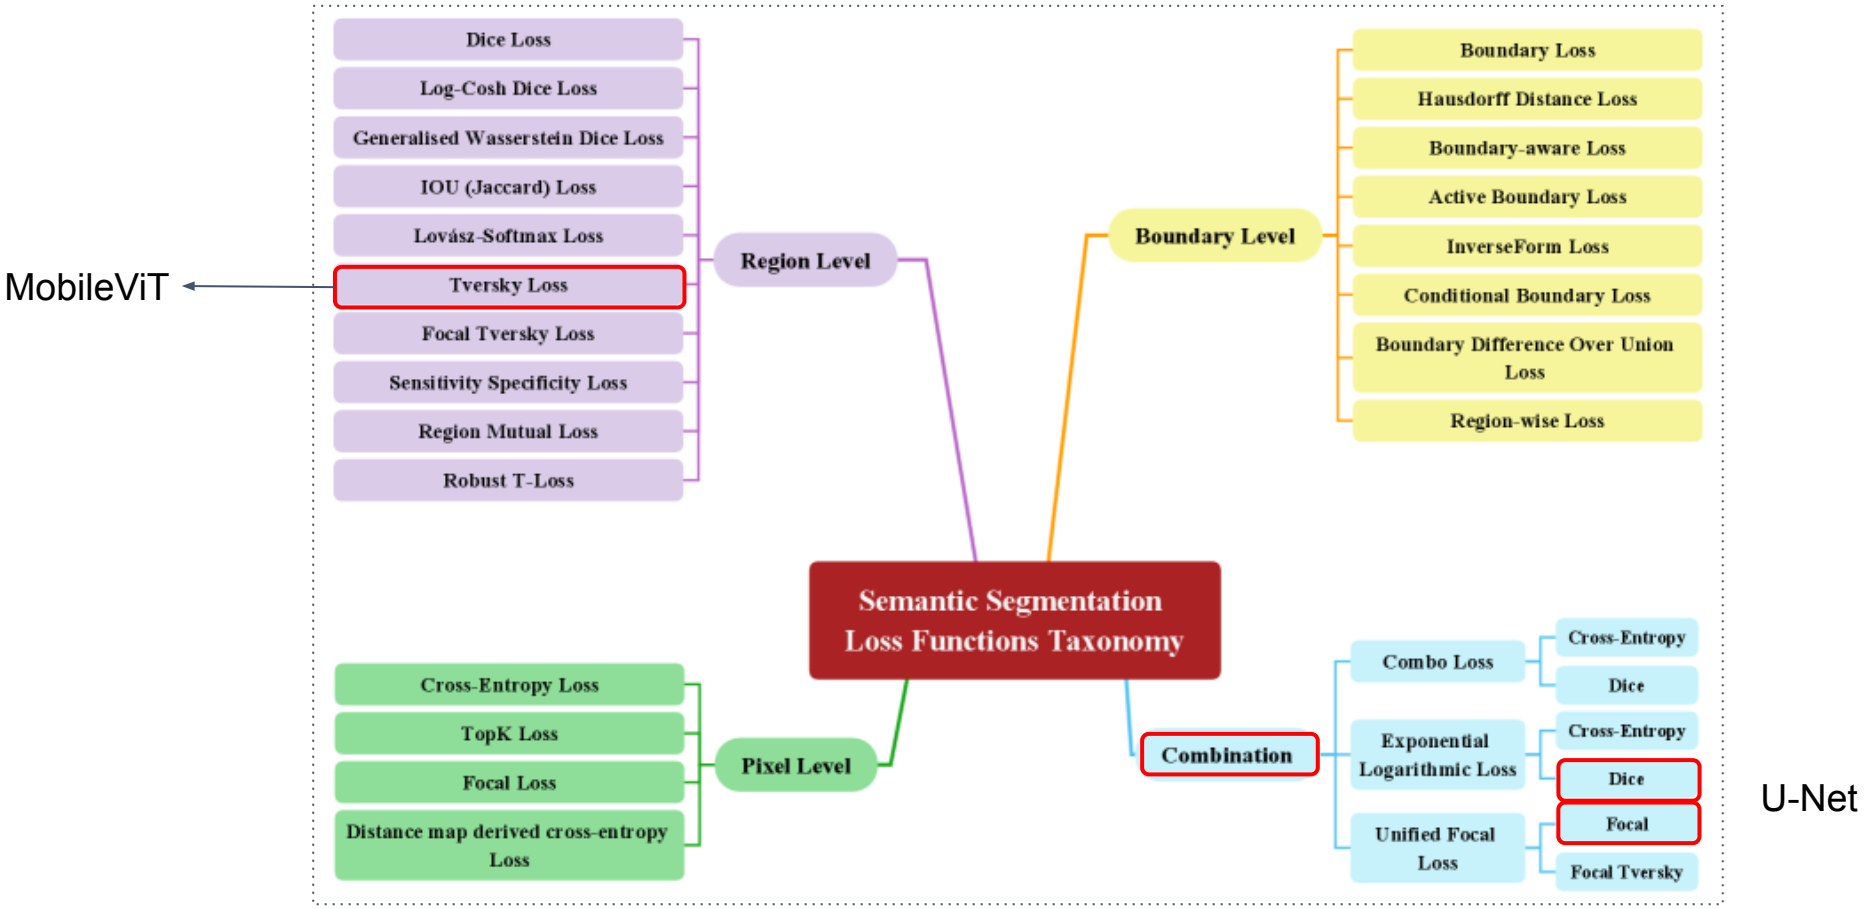

Figura 17 – Funções de perda para segmentação semântica[16]

Fundamentação Teórica

6. Redes Neurais Convolucionais – Modelo U-Net

- Elaborado em 2015, o algoritmo U-Net foi construído para segmentação de imagens médica, sendo amplamente aplicado em áreas como citologia e histologia;
- Foi pensado para conjuntos de imagens com tamanho limitado;
- Composto por uma arquitetura em "U", onde há um caminho de contração (*encoder*) e um caminho de expansão (*decoder*);
- Na etapa de *encoder* tem-se camadas de convolução e camada de *pooling* que visam a extração de características e redução da dimensionalidade;
- Na camada de *decoder* há um aumento da dimensionalidade e aumento da quantidade de informação.

Fundamentação Teórica

6. Redes Neurais Convolucionais – Modelo U-Net

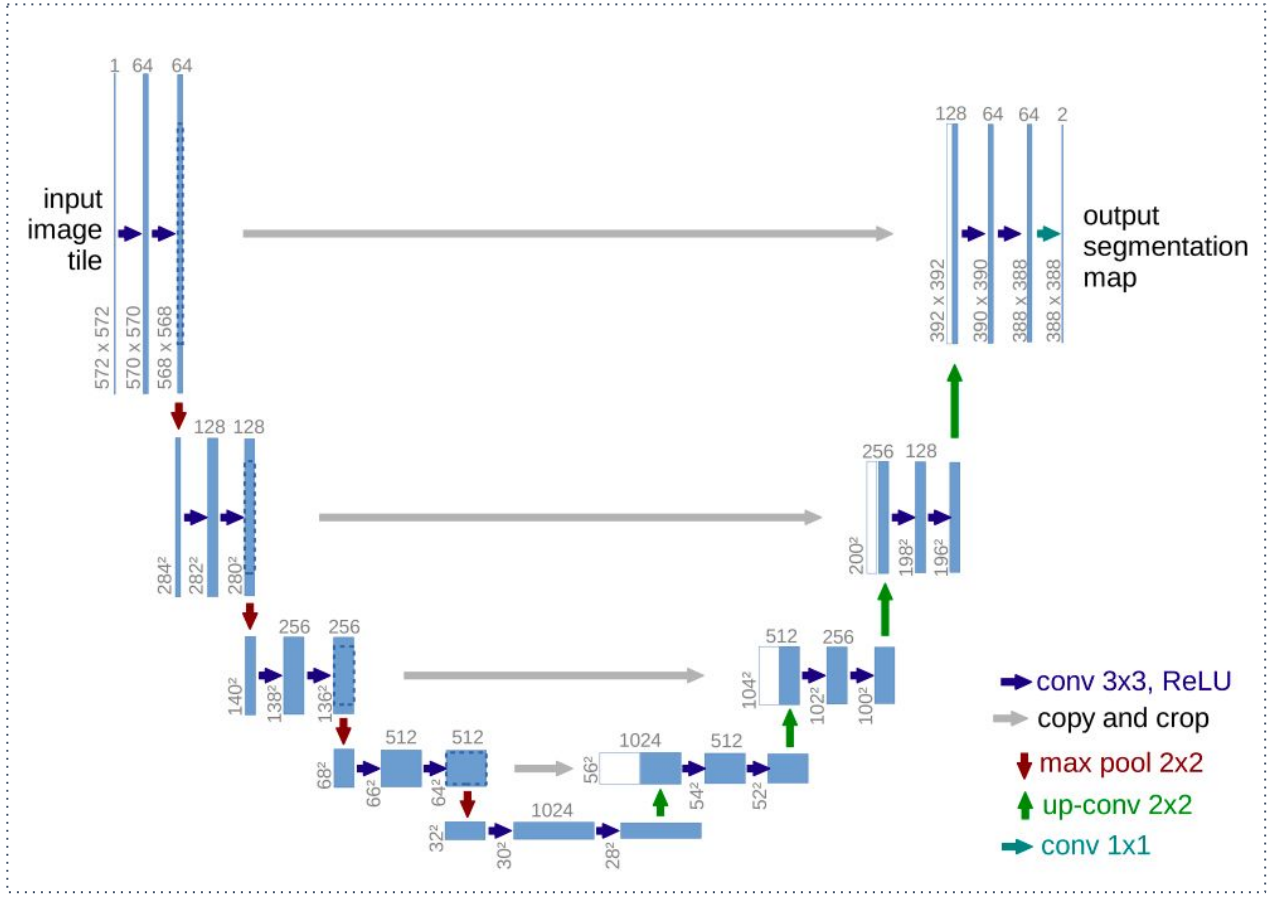

Figura 18 – Arquitetura U-Net[17]

[18] Dosovitskiy *et al.* (2020)

Fundamentação Teórica

6. Vision Transformers (ViTs)

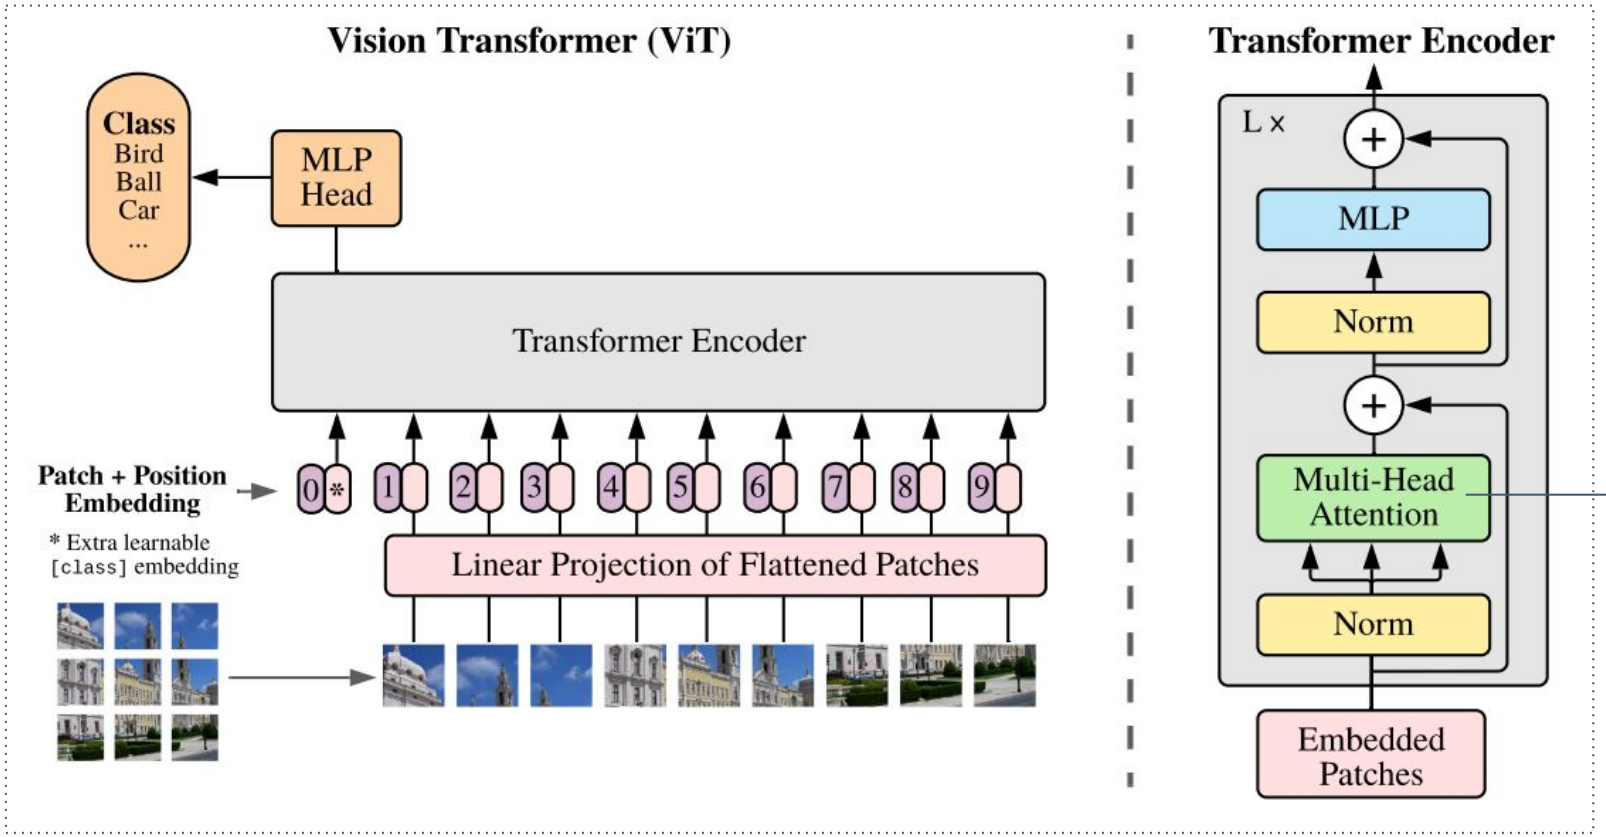

Características:
1. Generalista
2. Escalável
3. Expressivo

Query, Key, Value

Figura 19 – Arquitetura ViT[18]

Fundamentação Teórica

6. Vision Transformers (ViTs) – MobileViT

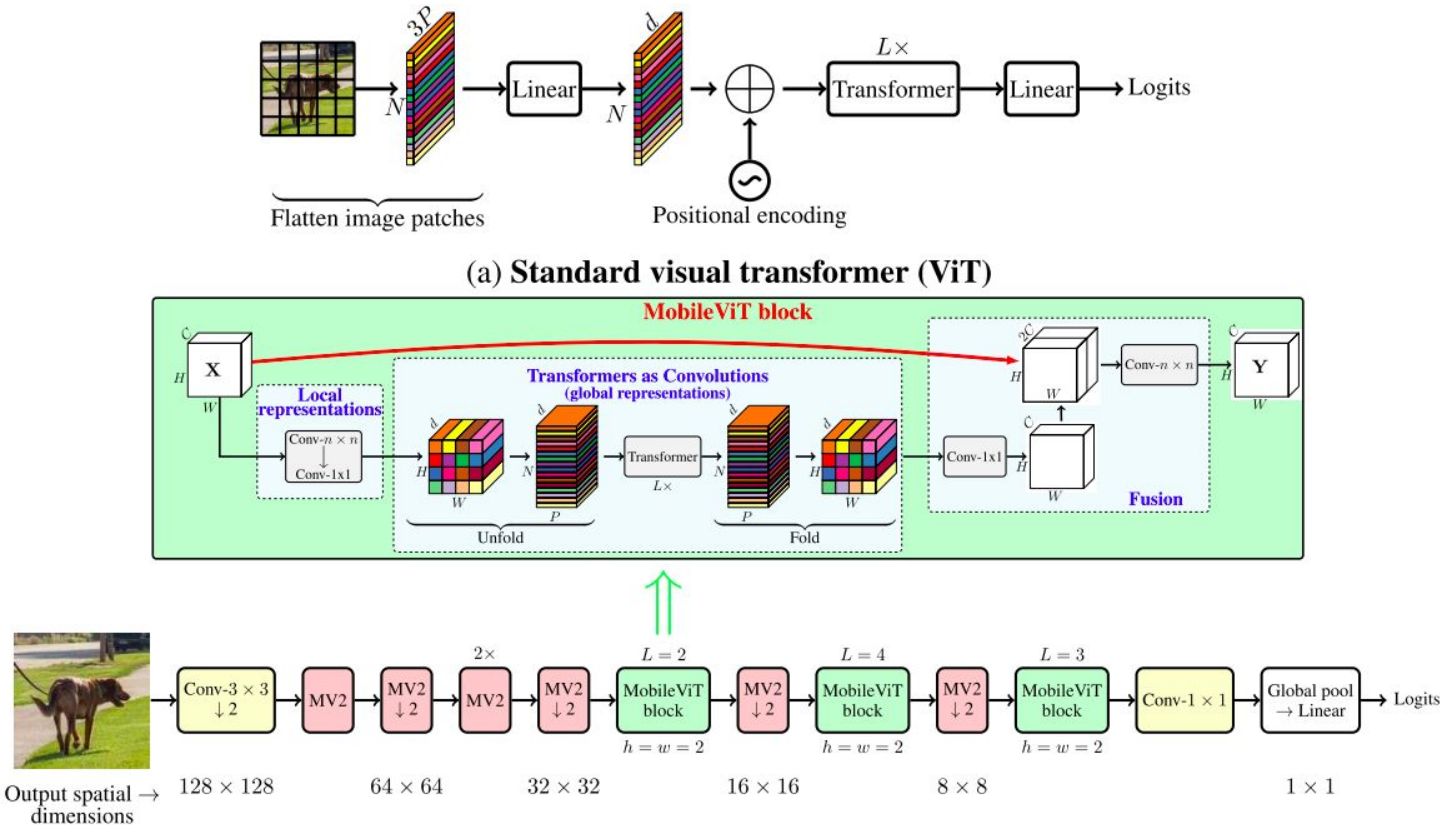

Figura 20 – Arquitetura MobileViT[19]

Metodologia

1. **Configuração do ambiente de desenvolvimento**

- Uso de Google Colaboratory para treinamento e inferência;
- Aplicação do tutorial de uso da U-Net da *framework* Tensorflow;
- Aplicação da Linguagem Python com *frameworks* de Visão Computacional.

Característica	Valor
Nome da GPU	Tesla T4
Versão do Driver	550.54.15
Versão CUDA	12.4
Memória Total	15360MiB

Figura 21 – Características do Google Colab

[20] Elaborado pelo autor.

Metodologia

2. Conjunto de imagens

- Escolha do *dataset* Indian Diabetic Retinopathy Image Dataset (IDRiD) por conter máscaras *ground truth* dos exsudatos lipídicos;
- 81 imagens de retina: 54 de treino e 27 imagens para validação de 4288x2848 pixels;

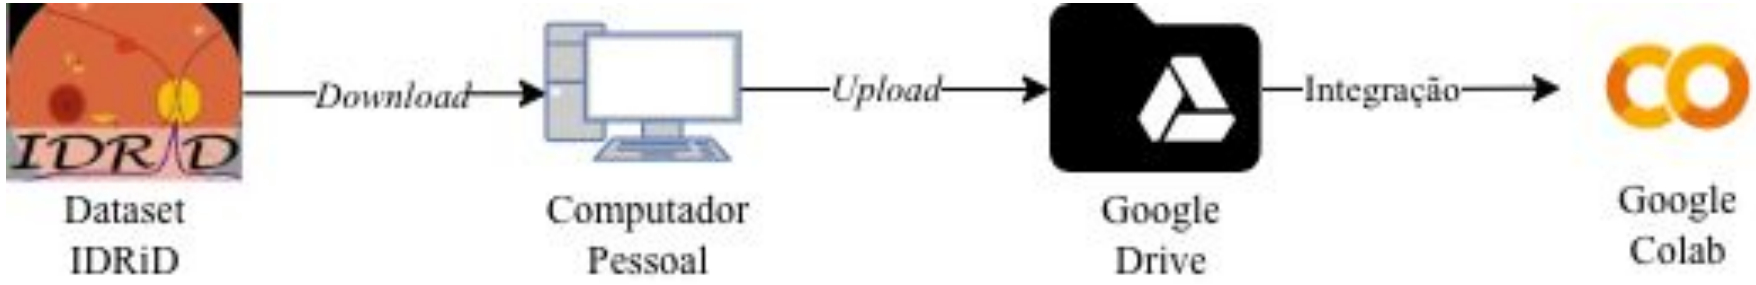

Figura 22 – Pipeline de *upload* da imagens no ambiente de desenvolvimento[20]

Metodologia

3. Pré-processamento das imagens

Foi aplicando um breve processamento das imagens para adequação aos algoritmos;

- Para as imagens originais:
  - Redimensionamento de 256 x 256 pixels;
  - Normalização para intervalo 0 a 1;
- Para as máscaras:
  - Binarização (0 para fundo e 1 para pixel de exsudato duro);
  - Interpolação por região mais próxima.

Para todo o conjunto:

- Pipeline de treinamento feito por lotes, para garantir otimização dos recursos;
- Uso de embaralhamento das imagens e *prefetch*.

[21] Elaborado pelo autor.

Metodologia

3. Pré-processamento das imagens

Data augmentation

Transformação das imagens visando aumentar o conjunto de dados de entrada para treinamento dos modelos

Para a U-Net:

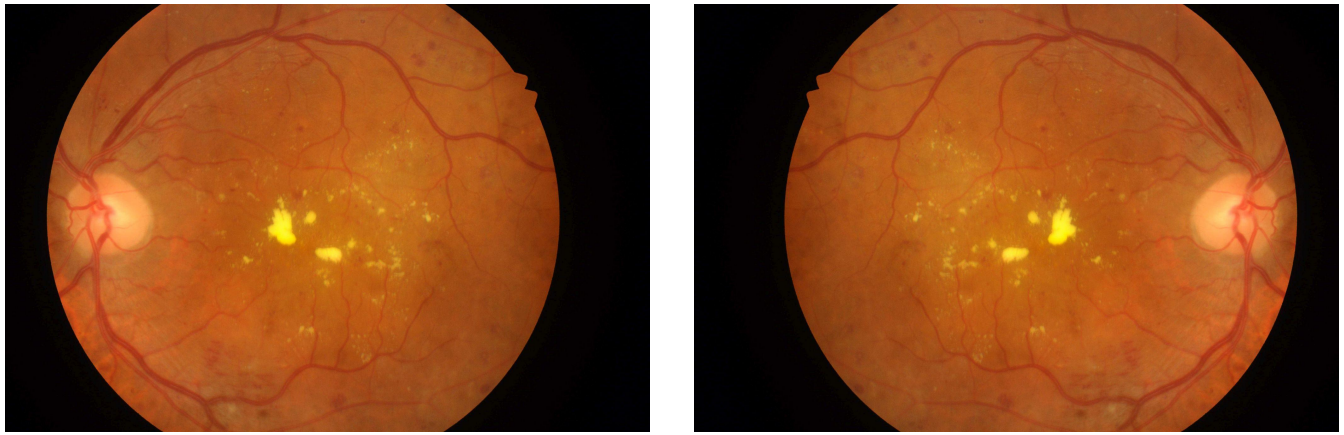

Figura 23 – Inversão horizontal[21]

Metodologia

3. Pré-processamento das imagens

Data augmentation
Transformação das imagens visando aumentar o conjunto de dados de entrada para treinamento dos modelos

Para o MobileViT:

Inversão vertical, rotação com múltiplos de 90º, o deslocamento vertical e horizontal da imagem em até 6,25%, redimensionamento do tamanho em até 10%, além de alterações aleatórias no brilho e contraste, bem como distorções na grade da imagem.

Metodologia

4. Modelagem da U-Net

- Uso de modelo pré-treinado no *encoder* – MobileNetV2 treinada com dados do conjunto de imagens ImageNet;
- Aplicação por *transfer learning*, descongelando-se as 30 últimas camadas para que o novo modelo generalize.

Atributo	**Valor adotado**
Otimizador	Adaptative Moment Estimation (Adam)
Taxa de aprendizado	0,0001
Função de perda	Focal + Dice loss
Épocas	100

Tabela 01 – Parâmetros adotados para o modelo U-Net + MobileNetV2

Metodologia

5. Modelagem do MobileViT

- Uso de modelo pré-treinado disponibilizado pelos autores da arquitetura na plataforma Hugging Face;
- Foi realizada a instanciação do modelo pré-treinado "apple/mobilevit-small", aplicando o parâmetro "*num_labels*" como 2, uma vez que se tratou de uma classificação binária.

Atributo	**Valor adotado**
Otimizador	AdamW
Épocas	30
Função de perda	Tversky
Scheduler da taxa de aprendizado	Cosine Annealing (T_max=30)
Patience	7 épocas

Tabela 02 – Parâmetros adotados para o modelo MobileViT

[22] Elaborado pelo autor.

Resultados e Conclusão

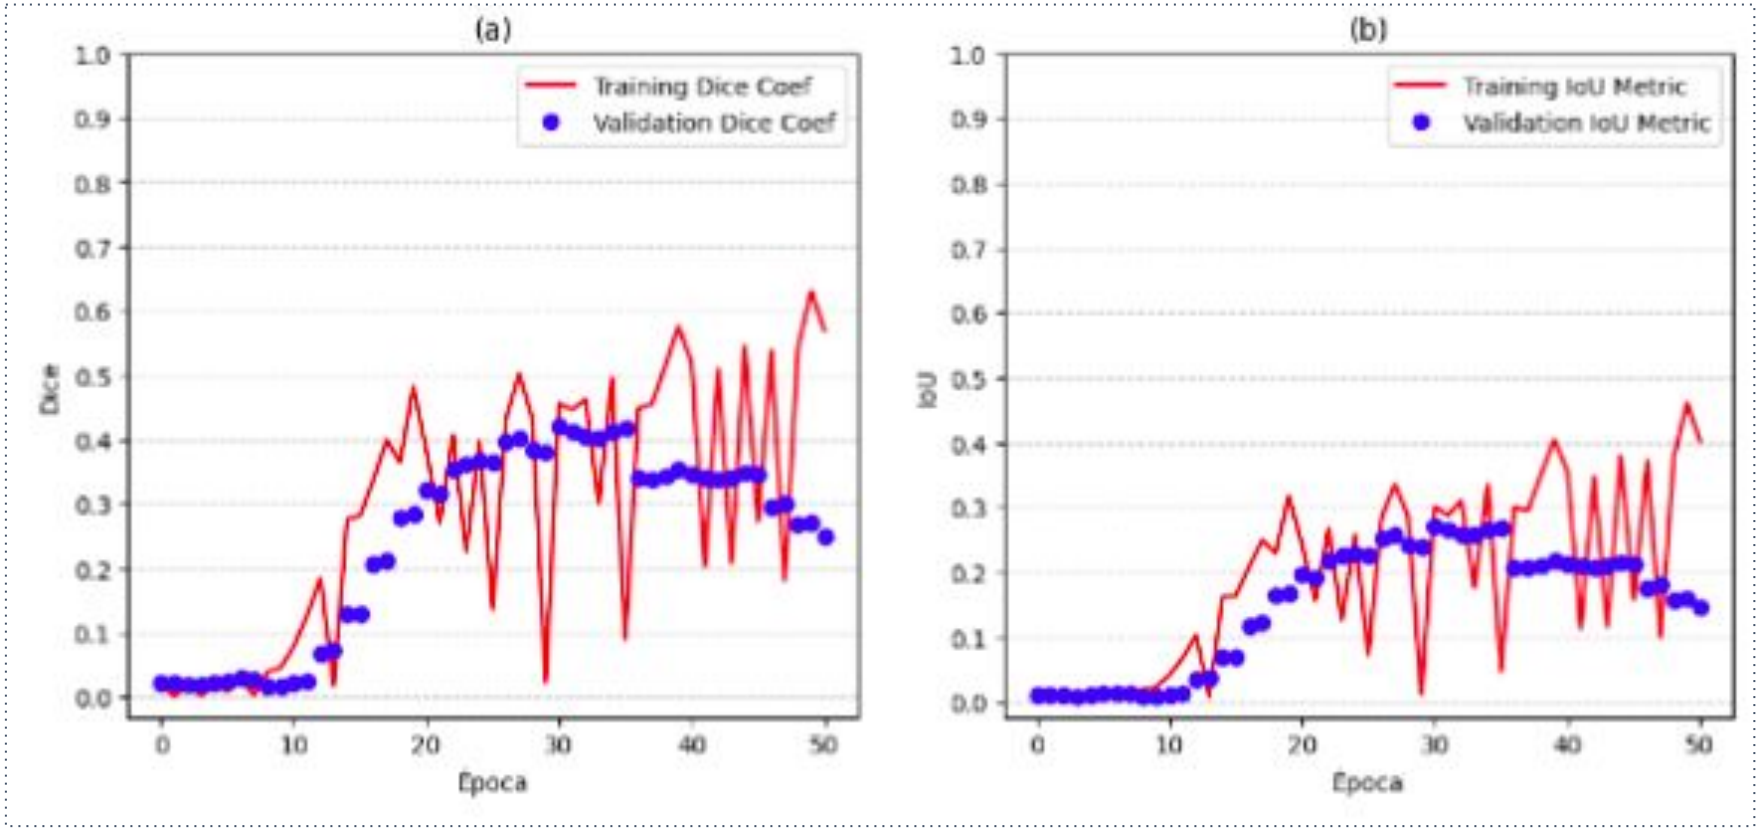

Figura 24 – Dice (a) e IoU (b) para 50 épocas de treinamento da U-Net[22]

[23] Elaborado pelo autor.

Resultados e Conclusão

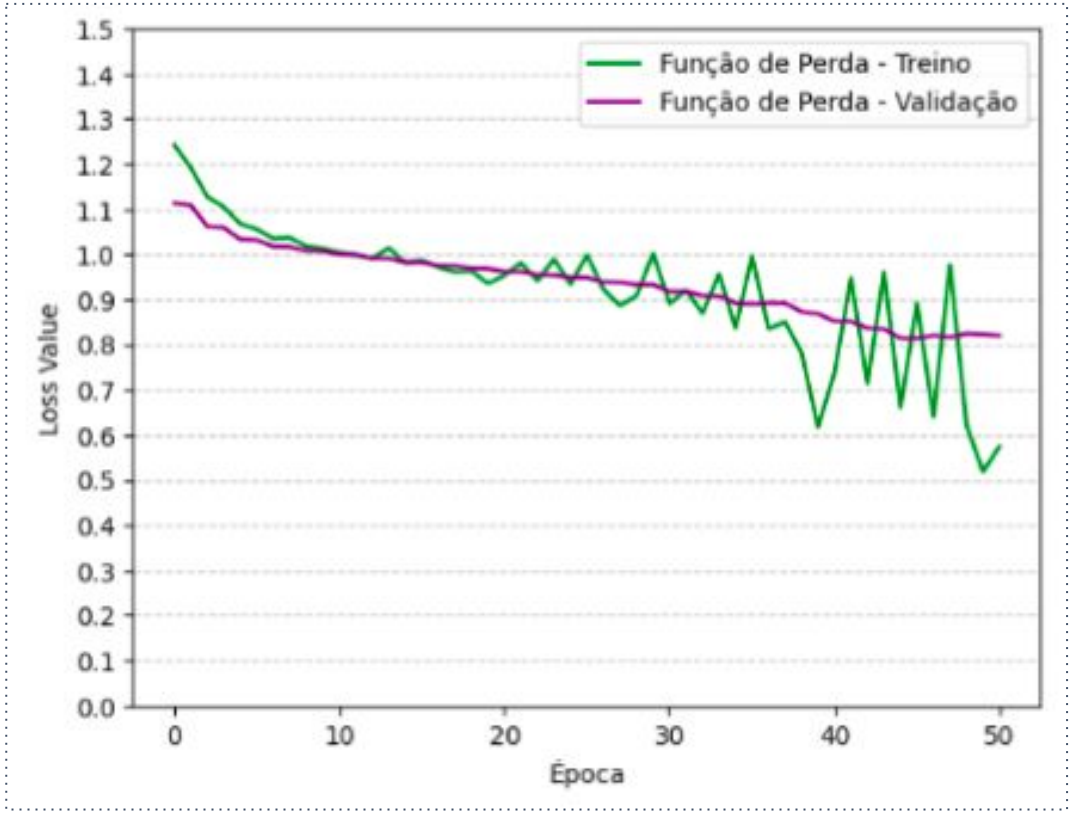

Figura 25 – Função de perda da U-Net[23]

[24] Elaborado pelo autor.

Resultados e Conclusão

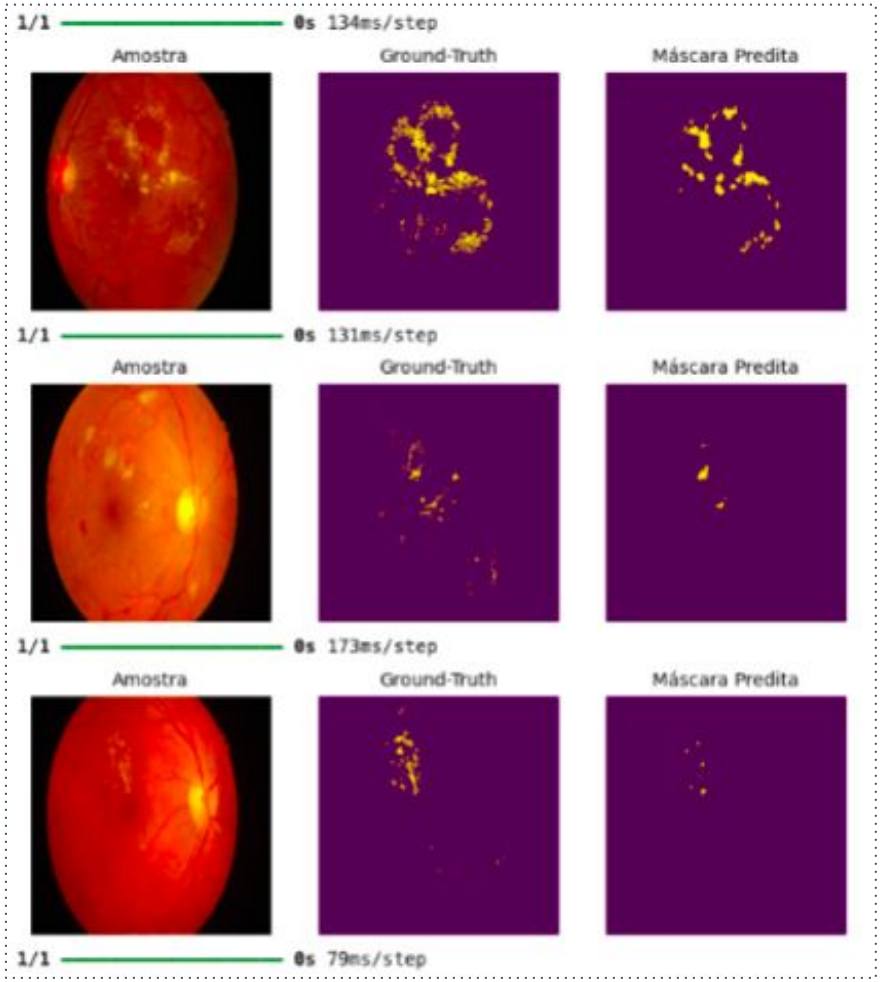

Figura 26 – Amostra de resultados da U-Net[24]

[25] Elaborado pelo autor.

Resultados e Conclusão

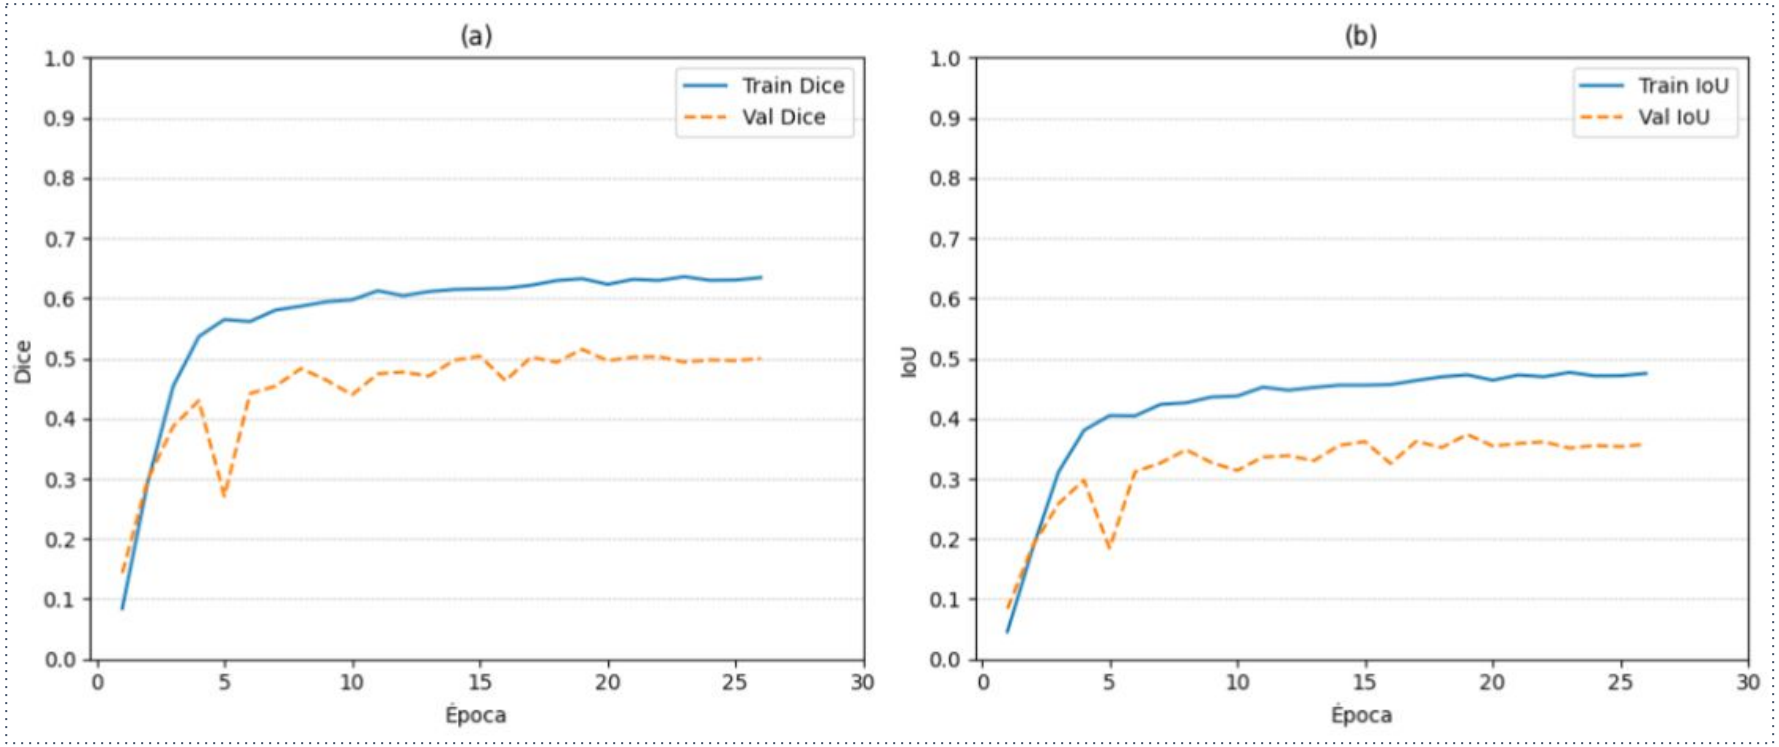

Figura 26 – Dice (a) e IoU (b) para 30 épocas de treinamento do MobileViT[25]

[266] Elaborado pelo autor.

Resultados e Conclusão

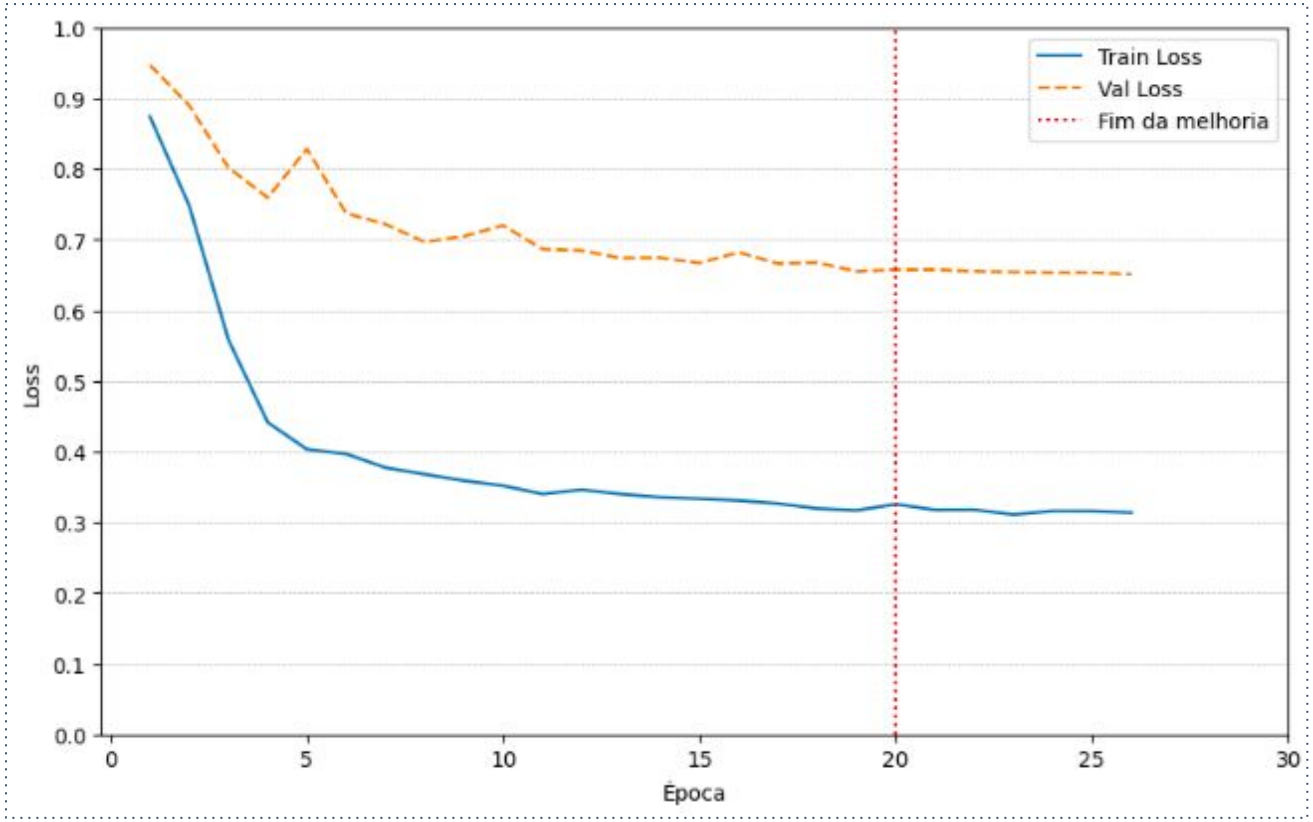

Figura 27 – *Tversky Loss* na MobileViT[26]

Resultados e Conclusão

Modelo	Dice Score	IoU	Tempo de Inferência (s)
MobileViT	**0.5152**	**0.3734**	**0.0015**
U-Net (MobileNetV2)	0.3452	0.2132	0.2491

Tabela 03 – Comparativo de desempenho entre o MobileViT e a U-Net com MobileNetV2

- O MobileViT demonstrou uma superioridade significativa, não apenas na qualidade da segmentação, cerca de 49% superior ao modelo baseado em CNN, mas principalmente na eficiência computacional. O tempo de inferência de 0,0015 segundos sugere que o modelo é viável para aplicações em tempo real, representando um valor significativamente mais rápido que a U-Net.

Resultados e Conclusão

Modelo	Dice Score	IoU	Tempo de Inferência (s)
MobileViT	**0.5152**	**0.3734**	**0.0015**
U-Net (MobileNetV2)	0.3452	0.2132	0.2491

Tabela 03 – Comparativo de desempenho entre o MobileViT e a U-Net com MobileNetV2

- O MobileViT demonstrou uma superioridade significativa, não apenas na qualidade da segmentação, cerca de 49% superior ao modelo baseado em CNN, mas principalmente na eficiência computacional. O tempo de inferência de 0,0015 segundos sugere que o modelo é viável para aplicações em tempo real, representando um valor significativamente mais rápido que a U-Net.

Resultados e Conclusão

Proposições de melhorias:

- Experimentação de procedimentos mais robustos de *data augmentation*, principalmente para o modelo baseado em CNN. Além disso, propõe-se uso de *grid search* para ajuste de hiperparâmetros como, por exemplo, taxa de aprendizado e otimizadores;

- Exploração de outros modelos de *encoder* para a U-Net, como *EfficientNet* (BAHETI et al., 2020);

- Implementação de técnicas como *pruning* (poda) e/ou *quantization* (quantização), poderão aprimorar a otimização dos algoritmos, tornando seu treinamento mais leve.

Referências Bibliográficas

AZAD, R.; HEIDARY, M.; YILMAZ, K.; HüTTEMANN, M.; KARIMIJAFARBIGLOO, S.; WU, Y.; SCHMEINK, A.; MERHOF, D. Loss functions in the era of semantic segmentation: A survey and outlook. 12 2023. Disponível em: https://arxiv.org/pdf/2312.05391v1.

BAHETI, B.; INNANI, S.; GAJRE, S.; TALBAR, S. Eff-unet: A novel architecture for semantic segmentation in unstructured environment. **IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops**, IEEE Computer Society, p. 1473–1481, 6 2020. ISSN 21607516. Disponível em: https://ieeexplore.ieee.org/document/9150621.

BRASIL. **Portaria Conjunta SAES/SCTIE/MS nº 17, de 01 de outubro de 2021**. Ministério da Saúde, 2021. Portal CONITEC. Aprova o Protocolo Clínico e Diretrizes Terapêuticas da Retinopatia Diabética. Disponível em: https://www.gov.br/conitec/pt-br/midias/protocolos/20211220_portal_retinopatia_diabetica.pdf.

CISNEROS-GUZMáN, F.; TOVAR-ARRIAGA, S.; PEDRAZA, C.; GONZáLEZ-GUTIERREZ, A. Classification of diabetic retinopathy based on hard exudates patterns, using images processing and svm. **2019 IEEE Colombian Conference on Applications in Computational Intelligence, ColCACI 2019 - Proceedings**, Institute of Electrical and Electronics Engineers Inc., 6 2019. Disponível em: https://ieeexplore.ieee.org/document/8781802.

Data Science Academy. **Deep Learning Book**. 2025. Disponível em: https://www.deeplearningbook.com.br/. Acesso em: 07 jan. 2026.

DATACAMP. **Explicação das funções de perda no aprendizado de máquina**. 2024. Disponível em: https://www.datacamp.com/pt/tutorial/loss-function-in-machine-learning. Acesso em: 08 jan. 2026.

Referências Bibliográficas

DOSOVITSKIY, A.; BEYER, L.; KOLESNIKOV, A.; WEISSENBORN, D.; ZHAI, X.; UNTERTHINER, T.; DEHGHANI, M.; MINDERER, M.; HEIGOLD, G.; GELLY, S.; USZKOREIT, J.; HOULSBY, N. An image is worth 16x16 words: Transformers for image recognition at scale. **ICLR 2021 - 9th International Conference on Learning Representations**, International Conference on Learning Representations, ICLR, 10 2020. Disponível em: https://arxiv.org/pdf/2010.11929.

ESTEVAM, R. **Redes Neurais Convolucionais**. 2019. Disponível em: https://medium.com/turing-talks/turing-talks-23-modelos-de-predi%C3%A7%C3%A3o-redes-neurais-convolucionais-d364654a34de.

GROUP, E. R. Grading diabetic retinopathy from stereoscopic color fundus photographs—an extension of the modified airlie house classification: Etdrs report number 10. **Ophthalmology**, v. 98, p. 786–806, 5 1991. Disponível em: https://www.sciencedirect.com/science/article/pii/S0161642013380129.

IBM. **O que são redes neurais convolucionais?** Disponível em: https://www.ibm.com/br-pt/think/topics/convolutional-neural-networks.

LECUN, Y.; BOTTOU, L.; BENGIO, Y.; HAFFNER, P. Gradient-based learning applied to document recognition. **Proceedings of the IEEE**, v. 86, p. 2278–2324, 11 1998. ISSN 00189219. Disponível em: https://ieeexplore.ieee.org/document/726791.

Referências Bibliográficas

MATIAS, A. V.; AMORIM, J. G. A.; MACARINI, L. A. B.; CERENTINI, A.; ONOFRE, A. S. C.; ONOFRE, F. B. D. M.; DALTOé, F. P.; STEMMER, M. R.; WANGENHEIM, A. von. What is the state of the art of computer vision-assisted cytology? a systematic literature review. **Computerized Medical Imaging and Graphics**, Pergamon, v. 91, p. 101934, 7 2021. ISSN 0895-6111. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0895611121000835?via%3Dihub.

MEHTA, S.; RASTEGARI, M. Mobilevit: Light-weight, general-purpose, and mobile-friendly vision transformer. **ICLR 2022 - 10th International Conference on Learning Representations**, International Conference on Learning Representations, ICLR, 10 2021. Disponível em: https://arxiv.org/pdf/2110.02178.

PORWAL, P.; PACHADE, S.; KAMBLE, R.; KOKARE, M.; DESHMUKH, G.; SAHASRABUDDHE, V.; MERIAUDEAU, F. **Indian Diabetic Retinopathy Image Dataset (IDRiD)**. IEEE Dataport, 2018. Disponível em: https://dx.doi.org/10.21227/H25W98.

PRAYOGO, M. E.; ZAHARO, A. F.; DAMAYANTI, N. N. R.; WIDYAPUTRI, F.; THOBARI, J. A.; SUSANTI, V. Y.; SASONGKO, M. B. Accuracy of low-cost, smartphone-based retinal photography for diabetic retinopathy screening: A systematic review. **Clinical Ophthalmology (Auckland, N.Z.)**, Dove Medical Press Ltd, v. 17, p. 2459–2470, 8 2023. ISSN 11775483. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC10443682/.

RONNEBERGER, O.; FISCHER, P.; BROX, T. U-net: Convolutional networks for biomedical image segmentation. 5 2015. Disponível em: http://arxiv.org/abs/1505.04597.

ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. **Psychological Review**, v. 65, 11 1958.

Obrigado!

Pedro Florencio de A. Neto: *pedroflorencio@alu.ufc.br*

https://www.linkedin.com/in/pedroflorencioneto/

https://github.com/PedroFlorencioNeto

http://lattes.cnpq.br/3043342272070609